

## 3 Présentation des données

Les données fournies par les chercheuses Marwa Hamdi et Noura Joudieh consistent en un fichier au format CSV contenant 30 688 lignes. Chaque ligne suit la structure suivante : "UserID, Timestamp, StudentEvent".

### 3.1 Quelques statistiques

Voici une analyse statistique des données :

- **Nombre total d'utilisateurs uniques (UserID)** : 274.
- **Nombre total d'événements uniques (StudentEvent)** : 38.
- **Utilisateur le plus actif** : Le UserID "std160" est présent 533 fois dans les données.
- **Événement le plus fréquent** : "viewed\_course\_core" apparaît 9 803 fois, représentant une part significative des données.

Ces statistiques mettent en évidence la distribution des activités parmi les utilisateurs et les événements, soulignant une concentration importante autour de certains utilisateurs et événements fréquents.

### 3.2 Analyse temporelle

Pour mieux comprendre la répartition des événements dans le temps, la figure 3 présente le nombre d'événements enregistrés par jour. Ce graphique révèle des pics d'activité significatifs à certaines périodes, suivis de phases de moindre activité. Ces variations peuvent refléter des événements académiques clés ou des phases d'utilisation intensive de la plateforme Moodle.




FIGURE 3 – Réseau de pétri

Une baisse significative est observable entre juillet 2016 et septembre 2017. Cette période de faible activité peut s'expliquer par plusieurs hypothèses :

- **Interruption dans la collecte des données** : Il est possible que des problèmes techniques ou des changements dans la configuration du système aient empêché l'enregistrement des événements durant cette période.
- **Transition ou mise à jour de la plateforme** : Une mise à jour majeure ou une migration vers une nouvelle version de Moodle pourrait avoir temporairement affecté l'enregistrement des données.

### 3.3 Analyse des types d'événements

La figure 4 présente les 10 types d'événements les plus fréquents dans les données, accompagnés de leurs fréquences respectives.




FIGURE 4 – Top 10 des types d'événements par fréquence

Cette analyse complète met en avant la nature des interactions les plus courantes sur la plateforme, avec une forte prédominance des événements liés à la consultation de cours et de ressources.

### 3.4 Corrélations entre types d'événements

La figure 5 présente une carte de chaleur (heatmap) illustrant les corrélations entre différents types d'événements. Chaque élément de cette matrice représente le degré de corrélation entre deux événements, allant de 0 (aucune corrélation) à 1 (corrélation parfaite).




FIGURE 5 – Carte de chaleur des corrélations entre types d'événements

Cette visualisation met en évidence les relations entre différents types d'événements, en identifiant des schémas récurrents ou des dépendances potentielles. Les zones rouges en dehors de la diagonale indiquent une forte corrélation, ce qui signifie que les événements correspondants sont souvent liés ou apparaissent ensemble. En revanche, les zones bleues traduisent une faible ou absence de corrélation, suggérant que ces événements sont indépendants les uns des autres.

#### 4.2.6 Bert

Le modèle `BERTForSequenceClassification` est utilisé pour prédire le prochain événement dans une séquence d'interactions d'un étudiant avec la plateforme. BERT (Bidirectional Encoder Representations from Transformers) est un modèle de langage basé sur l'architecture Transformer qui est particulièrement efficace pour les tâches de classification sur des séquences de texte.

En raison de sa capacité à capturer les relations contextuelles bidirectionnelles entre les mots dans une séquence, BERT est particulièrement bien adapté pour des tâches telles que la prédiction d'événements sur des séries temporelles complexes.

#### Préparation des données

Les étapes principales de prétraitement incluent :

1. **Tri des données** : Les interactions sont triées par UserID et par ordre chronologique (Timestamp) pour garantir la cohérence des séquences temporelles.
2. **Encodage des événements** : Chaque type d'événement est mappé à un identifiant numérique unique. Par exemple :
  - `viewed_course_core` → 0
  - `viewed_course_module_mod_folder` → 1
  - `viewed_course_module_mod_url` → 2
3. **Formation des séquences** : Les interactions sont regroupées par utilisateur pour former des séquences d'événements chronologiques. Des paires entrée-sortie sont générées pour préparer l'entraînement du modèle :
  - **Entrée** : Une séquence de longueur fixée (e.g., 533 événements).
  - **Sortie** : L'événement suivant dans la séquence.

#### 4.2.7 Hyperparamètres du Modèle BERT

Les hyperparamètres suivants sont utilisés pour l'entraînement du modèle :

- **Taille du batch** : 32
- **Taux d'apprentissage initial** :  $5 \times 10^{-5}$
- **Nombre d'époques** : 30
- **Longueur maximale des séquences** : 533
- **Nombre de classes de sortie** : 38 (nombre d'événements distincts dans le dataset)

#### Optimisation et Régularisation

Le modèle utilise l'optimiseur AdamW (Adam avec pondération de L2) pour l'entraînement. Adam est un optimiseur adaptatif populaire qui ajuste les taux d'apprentissage pour chaque paramètre en fonction de ses gradients précédents. L'ajout de la pondération L2 (ou *weight decay*) permet d'introduire une régularisation afin de prévenir le sur-apprentissage.

Une régularisation par *weight decay* est appliquée pour éviter que le modèle ne devienne trop complexe et qu'il sur-adapte aux données d'entraînement. Cela peut être particulièrement utile lorsque le nombre d'exemples d'entraînement est relativement faible par rapport à la complexité du modèle.

Un scheduler de taux d'apprentissage est également utilisé pour réduire le taux d'apprentissage à chaque époque, afin d'améliorer la convergence du modèle au fur et à mesure de l'entraînement. Cela permet d'atteindre une meilleure précision finale sans que le modèle ne dépasse les limites optimales.

#### Fonction de perte et traitement du déséquilibre des classes

Le déséquilibre des classes est un problème courant dans les tâches de classification, notamment lorsque certaines classes sont beaucoup plus fréquentes que d'autres. Pour résoudre ce problème, la fonction de perte *Focal Loss* est utilisée. Cette fonction pondère les erreurs difficiles (celles qui sont mal classifiées) et réduit l'impact des exemples déjà bien classifiés (Figure 10).

La formule de la *Focal Loss* est définie comme suit :

$$FL(p_t) = -\alpha_t(1 - p_t)^{\gamma} \log(p_t)$$




FIGURE 10 – Courbes de perte d'entraînement et de validation.

- $p_t$  représente la probabilité prédite pour la classe correcte.
- $\alpha_t$  est un facteur d'équilibrage qui attribue plus de poids aux classes minoritaires.

- $\gamma$  est un hyperparamètre qui permet d'ajuster l'importance accordée aux erreurs mal classifiées. Un  $\gamma$  élevé accentue l'apprentissage sur les exemples difficiles à classer, tout en réduisant l'impact des exemples correctement classés.

### Intuition derrière la Focal Loss

La fonction de perte *Focal Loss* permet de mieux gérer les situations où certaines classes sont beaucoup plus fréquentes que d'autres. Par exemple, dans un ensemble de données où la classe "vue\_cours\_module" est beaucoup plus fréquente que la classe "vue\_cours\_ressource", la *Focal Loss* accorde moins d'importance aux erreurs commises sur la classe majoritaire (facilement classifiée) et se concentre sur les erreurs des classes moins fréquentes. Cela permet au modèle d'apprendre plus efficacement dans les scénarios déséquilibrés.

### Réglage des Hyperparamètres avec Optuna

Pour optimiser les hyperparamètres de la *Focal Loss*, nous avons utilisé Optuna, une bibliothèque de réglage d'hyperparamètres automatique. Optuna explore différents ensembles d'hyperparamètres et trouve les meilleurs paramètres pour le modèle.

**Fonction Objective pour Optuna** Une fonction objective a été définie pour minimiser la perte de validation. Cette fonction a été utilisée par Optuna pour explorer différents ensembles d'hyperparamètres et trouver les meilleurs paramètres pour le modèle.

**Étude Optuna** Une étude Optuna a été créée pour optimiser les hyperparamètres sur plusieurs essais. Les meilleurs paramètres trouvés par Optuna ont été utilisés pour entraîner le modèle final.

#### 4.2.8 Évaluation et Performance du Modèle

Les performances du modèle sont évaluées en utilisant les métriques suivantes :

- **Précision**
- **Rappel**
- **F1-Score**

Les résultats sont présentés dans le tableau (Table 2). ci-dessous, en indiquant les performances pour chaque événement prédictif :

| Classe                                | Précision | Rappel | F1-Score | Support |
|---------------------------------------|-----------|--------|----------|---------|
| viewed_course_core (0)                | 0.45      | 0.32   | 0.37     | 277     |
| viewed_course_module_mod_folder (1)   | 0.50      | 0.14   | 0.22     | 14      |
| viewed_course_module_mod_url (2)      | 0.38      | 0.44   | 0.41     | 25      |
| viewed_course_module_mod_resource (3) | 0.53      | 0.82   | 0.64     | 286     |
| <b>Moyenne pondérée</b>               | 0.76      | 0.77   | 0.75     | 2499    |

TABLE 2 – Performance du modèle pour les différentes classes d'événements.

### Discussion des Résultats

Les résultats montrent plusieurs points importants :

- **Performance sur les classes dominantes** : Les classes avec un grand nombre d'exemples ont une précision et un rappel relativement élevés, ce qui reflète la capacité du modèle à bien s'adapter aux classes majoritaires.
- **Performance sur les classes minoritaires** : Les classes avec un faible nombre d'exemples souffrent d'une faible performance. Cela peut être partiellement atténué en utilisant des techniques telles que la sur-échantillonnage ou l'augmentation des données. L'application de la *Focal Loss* a légèrement amélioré la performance sur les classes minoritaires, mais il reste encore des marges d'amélioration.